Assembly Megahit

2022-01-20 20193852 문유빈

- 1) Goal : Megahit 프로그램을 사용해 assembly 하기
- 2) Shotgun pipeline(*현재 진행된) Raw data -> QC -> FastUniq -> (Host 제거) -> Assembly
 - * 현재 하고 있는 샘플은 물이므로 따로 host 제거 과정이 필요하지 않음
 - * Assembly는 짧은 reads를 이어 contig로 만드는 과정
- 3) Megahit
- MEGAHIT is an ultra-fast and memory-efficient NGS assembler. It is optimized for metagenomes, but also works well on generic single genome assembly (small or mammalian size) and single-cell assembly.
- 빠르고 괜찮은 퀄리티를 자랑
 - ** Assembly tool들은 각각의 장단점이 존재
 - -> assembly comparison 검색 시 다양한 툴 비교 가능
- Parameter
 - ◎ -1 <pe1> comma-separated list of fasta/q paired-end #1 files, paired with files in <pe2> → 첫 번째 파일, 파일2와 pair
 - © -2 <pe2> comma-separated list of fasta/q paired-end #2 files, paired with files in <pe1> → 두 번째 파일, 파일1과 pair
 - ◎ -r <se> comma-separated list of fasta → unpaired 파일 1개
 - - meta-sensitive: '--min-count 1 -k-list 21,29,39,49,...,129,141' → 리드를 21, 29, 39, 49. ... , 141로 자름
 - meta-large: '--k-min 27 --k-max 127 --k-step 10'(large & complex metagenomes, like soil) → 리드를 27, 37, 47, ..., 127로 자름
 - ** 토양 같은 파일(대용량)은 meta-large 사용, 우린 meta-sensitive 사용

** k-mer


k-mer는 일반적으로 문자열(string)에서 가능한 모든 부분문자열(substring)의 길이 k를 의미한다. 유전체학에서 k-mer는 DNA sequencing으로 얻은 read의 모든 가능한 부분 서열 (의 길이 k)을 의미한다. L이라는 길이의 문자열이 주어졌을 때, k-mer의 양은 L - k + 1 이며, n 개(예를 들어 DNA의 ATCG의 경우 4)에 대해 가능한 k-mer의 개수는 nk 이다.

k-mer는 일반적으로 sequence assembly에 사용되지만, sequence alignment에도 사용될 수 있다.인간 유전체 관점에서, 돌연변이율의 가변성을 설명하는데 다양한 길이의 k-mer가 사용되었다.

https://m.blog.naver.com/PostView.naver?isHttpsRedirect=true&blogId=naturelove87&logNo=221561868710

- ◎ -m <float> max memory in byte to be used in SdBG construction
- ◎ -t <int> number of CPU threads, at least 2 if GPU enabled.
- O -o <string> output directory [./megahit_out]
- ◎ --out-prefix <string> output prefix → 생성될 파일 이름 설정
- ◎ --min-contig-len <int> minimum length of contigs to output
 → default = 200, 우린 500으로 설정해 최소 500bp 이상만

4) Megahit xshell 입력



xshell 입력 코드

[guest01@smel0:ybFastUniq]\$ /home/bioware/bin/megahit -1 /home/bbang9/Project/2021/KOPRI/shotgun/Penguin_gut/Analysis/PG-16-sps-01/PG-16-sps-01.rmd.1.fastq -2 /home/bbang9/Project/2021/KOPRI/shotgun/Penguin_gut/Analysis/PG-16-sps-01/QcReads/QC.unpaired.trimmed.fastq --presets meta-sensitive -m 0.35 -t 16 -o PG-16-sps-01 megahit --out-prefix PG-16-sps-01 --min-contig-len 500

- ① /home/bioware/bin/megahit => megahit 절대 경로
 - * 절대 경로 모를 때는 xshell에 which megahit 입력하면 나옴

[guest01@smel0:PG-16-sps-01_megahit]\$ which megahit /home/bioware/bin/megahit

- ② -1 첫 번째 파일 경로/파일 명
- ③ -2 두 번째 파일 경로/파일 명
- ④ -r unpaired 파일 경로/파일 명

진주 언니 파일 경로

- ⑤ --presets meta-sensitive
- 6 -m 0.35
- ⑦ -t 16
- 8 -o PG-16-sps-01_megahit
- 9 --out-prefix PG-16-sps-01
- ① --min-contig-len 500

내 경로에 생성되는 output 파일

5) 실행 경과

실행 중 몇 시간 소요됨

6) 결과

>vbMegahit 폴더

```
[guest01@smel0:ybMegahit]$ ll
total 0
drwxrwxr-x 3 guest01 guest0<u>1</u> 136 Jan 21 10:01 PG-16-sps-01_megahit
```

>PG-16-sps-01_megahit 폴더

- * intermediate_contigs 폴더는 assembly 하면서 중간에 생긴, 사용한 것들
- * opts.txt엔 내가 넣은 옵션

```
1
/home/bbang9/Project/2021/KOPRI/shotgun/Penguin_gut/Analysis/PG-16-sps-01/PG-16-sps-01.rmd.1.fastq
-2
/home/bbang9/Project/2021/KOPRI/shotgun/Penguin_gut/Analysis/PG-16-sps-01/PG-16-sps-01.rmd.2.fastq
-r
/home/bbang9/Project/2021/KOPRI/shotgun/Penguin_gut/Analysis/PG-16-sps-01/QcReads/QC.unpaired.trimmed.fastq
--presets
meta-sensitive
-m
0.35
-t
16
-0
PG-16-sps-01_megahit
--out-prefix
PG-16-sps-01
--min-contig-len
500
MEGAHIT_TEMP_DIR: PG-16-sps-01_megahit/tmp/
```

*** PG-16-sps-01.contigs.fa => 우리가 쓸 파일

k141 2 flag=1 multi=4.0000 len=515

>k141_3 flag=1 multi=3.0000 len=648

>k141_4 flag=1 multi=5.0000 len=512

* log => 상황 기록

** output info

contigs output by MEGAHIT

Brandon Seah edited this page on 14 Jan 2019 · 4 revisions

The FASTA file final.contigs.fa (or OUTPUT_PREFIX.contigs.fa if --out-prefix is specified) is the final result of the assembly. For files in the folder intermediate_contigs:

- kK.contigs.fa contains the contigs assembled from the de Bruijn graph of order-K, they can be converted to a SPAdes-like FASTG file for visualization
- kK.addi.fa contains the contigs assembled after iteratively removing local low coverage unitigs in the de Bruijn graph of
 order-K
- kK.local.fa contains the locally assembled contigs for k=K
- kK.final.contigs.fa contains the stand-alone contigs for k=K; if local assembly is turned on, the file will be empty
- > https://github.com/voutcn/megahit/wiki/contigs-output-by-MEGAHIT
- >> github에서 wiki 파트에 이런 좋은 정보 많음